

# 支持向量机

## 一、实验名称：支持向量机

## 二、实验目的

实现支持向量机，通过训练获得适当的参数。

## 三、实验原理

线性不可分的支持向量机需要实现软间隔最大化：

$$\min_{w,b,\zeta} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \zeta_i$$
$$s.t. \quad y_i(w^T x_i + b) \geq 1 - \zeta_i, \quad \zeta_i \geq 0, \quad \forall i = 1, \dots, N$$

这里的  $\zeta_i \geq 0$  是松弛变量，是硬间隔到软间隔的变化部分。它保证了在线性不可分的交界处，对越界的数据点进行宽容。

为获得其最小值，对不同参数求偏导，得到它们各自为 0 的条件，再带回，就可以得到该问题的对偶问题：

$$\min_a \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_i a_j y_i y_j x_i^T x_j - \sum_{i=1}^N a_i$$
$$s.t. \quad \sum_{i=1}^N a_i y_i = 0, \quad 0 \leq a_i \leq C, \quad \forall i = 1, \dots, N$$

该对偶问题满足 KKT 条件：

$$\begin{cases} \alpha_i \geq 0, & \mu_i \geq 0 \\ \xi_i \geq 0, & \mu_i \xi_i = 0 \\ y_i (w^\top X_i + b) - 1 + L_i \geq 0 \\ \alpha_i [y_i (w^\top X_i + b) - 1 + L_i] = 0 \end{cases}$$

利用拉格朗日乘子法求解该问题，增广拉格朗日函数如下：

$$L(\alpha, \lambda) = \frac{1}{2} \alpha^T \hat{X} \hat{X}^T \alpha - 1^T \alpha + \lambda y^T \alpha + \frac{\beta}{2} (y^T \alpha)^2$$

在迭代中获得拉格朗日参数：

$$\hat{\alpha}^k = \alpha^k - \eta \nabla L(\alpha^k, \lambda^k)$$
$$= \alpha^k - \eta (\hat{X} \hat{X}^T \alpha^k - 1 + \lambda^k y + \beta y^T \alpha^k y)$$
$$\alpha_i^{k+1} = \begin{cases} \hat{\alpha}_i^k & \text{if } 0 \leq \hat{\alpha}_i^k \leq C \\ 0 & \text{if } \hat{\alpha}_i^k < 0 \\ C & \text{if } \hat{\alpha}_i^k > C \end{cases}$$
$$\lambda^{k+1} = \lambda^k + \beta (y^T \alpha^{k+1})$$

根据拉格朗日参数，带回求解分类界面参数：

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$
$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

获得分类界面： $w^* \cdot x + b^* = 0$ ，得到分类决策函数： $f(x) = \text{sign}(w^* \cdot x + b^*)$ 。

该问题还可以转化为合页损失函数最小化：

$$\sum_{i=1}^N [1 - y_i(w \cdot x + b)]_+ + \lambda \|w\|^2$$

针对原始问题和对偶问题，将训练数据集中对应  $\alpha(\alpha) > 0$  的样本点称为支持向量，即线性可分位于间隔边界上的样本点，线性不可分位于间隔边界上及间隔边界内的样本点。

## 四、实验步骤

- 1、生成数据集：利用中心点加高斯噪音，生成两类数据集，样本量  $n=100$ ，维度为 2 维，并为两类加不同标签。
- 2、SVM 模型初始化：初始化系数  $w$  和  $b$ ，并初始化对偶问题变量  $\alpha(\alpha) = \text{zeros}(2*n, 1)$ 、拉格朗日参数  $\lambda(\lambda) = 0.1$ 、惩罚参数  $\beta(\beta) = 0.1$ 、惩罚参数  $C=0.3$ 、步长/学习率  $\eta(\eta) = 0.00005$ 、迭代次数  $m=100000$ 。
- 3、约束最优解：在迭代中，不断更新  $\alpha$  和  $\lambda$ ，并对超出  $[0, C]$  范围的  $\alpha$  设回边界值，具体如下：  
 $\alpha = \alpha - \eta * (X_{\text{hat}} * X_{\text{hat}}' * \alpha - 1 + \lambda * Y + \beta * Y' * \alpha * Y)$   
 $\lambda = \lambda + \beta * (Y' * \alpha)$
- 4、分类界面参数：根据迭代的结果，按照原理中给出的式子求解分类界面参数。
- 5、结果展示：在图像中标注数据集、分类超平面以及支持向量，并显示  $w$ 、 $b$  以及代码运行时间。
- 6、函数结果：利用原理中给出的相应函数，求得线性增广拉格朗日函数和合页损失函数的值，作为参考。
- 7、训练：改动参数（如上标红），进行调试训练，综合考虑，获得合适的参数。

## 五、代码

主要的训练部分已标红

```
% 数据样本生成
n = 100; % 样本量
center1 = [1,1]; % 数据中心（第二类：可分[6,6]，不可分[3,3]）
center2 = [3,3];
X = zeros(2*n,2); % 数据点（2维）：高斯噪声
X(1:n,:) = ones(n,1)*center1 + randn(n,2);
X(n+1:2*n,:) = ones(n,1)*center2 + randn(n,2);
Y = zeros(2*n,1); % 类别标签
Y(1:n) = 1;
Y(n+1:2*n) = -1;
X_hat = X .* Y;

%{
% 图一：数据点
figure(1)
set(gcf,'Position',[1,1,700,600], 'color','w')
set(gca,'FontSize',18)
plot(X(1:n,1),X(1:n,2),'go','LineWidth',1,'MarkerSize',10);
hold on;
```

```

plot(X(n+1:2*n,1),X(n+1:2*n,2),'b*','LineWidth',1,'MarkerSize',10);
hold on;
xlabel('x axis');
ylabel('y axis');
legend('class 1','class 2');
%}

% SVM 模型
tic()
alpha = zeros(2*n,1);      % 对偶问题变量 $\alpha$ 
lambda = 0.1;              % 拉格朗日参数 $\lambda$ 
beta = 0.1;                % 惩罚参数 $\beta$ 
C = 0.3;                   % 惩罚参数 C
eta = 0.00005;             % 步长 $\eta$ 
m = 100000;                % 迭代次数 m
for i=1:m                   % 求最优解
    alpha = alpha - eta*(X_hat*X_hat'*alpha-1+lambda*Y+beta*Y'*alpha*Y);
    alpha(alpha>C) = C;
    alpha(alpha<0) = 0;
    lambda = lambda + beta*(Y'*alpha);
end
idx = find(alpha<C&alpha>0); % 分类界面参数
len = length(idx);
j = idx(randi(len));
w = X_hat' * alpha;
b = Y(j)-sum(Y.*alpha.*X*X(j,:));
b_all = zeros(len,1);      % 观测不同 b 是否收敛
for i=1:len
    b_all(i) = Y(i)-sum(Y.*alpha.*X*X(i,:));
end
L1 =
1/2*alpha'*(X_hat*X_hat')*alpha-sum(alpha)+lambda*Y'*alpha+beta/2*(Y'*alpha)
^2; % 线性增广拉格朗日函数
z = 1-Y.*(X*w+b);
z(z<0) = 0;
L2 =
sum(z)+1/2/C*(w'*w);
% 合页损失函数
disp(L1)
disp(L2)
toc()

% 图二：分类器可视图（x1 为横轴，y 为纵轴，1 为分类界面，2、3 为间隔边界）
x1 = -2 : 0.00001 : 7;

```

```

y1 = ( -b * ones(1,length(x1)) - w(1) * x1 )/w(2);
y2 = ( ones(1,length(x1)) - b * ones(1,length(x1)) - w(1) * x1 )/w(2);
y3 = ( -ones(1,length(x1)) - b * ones(1,length(x1)) - w(1) * x1 )/w(2);
figure(2)
set(gcf,'Position',[1,1,700,600], 'color','w')
set(gca,'FontSize',18)
plot(X(1:n,1),X(1:n,2),'go','LineWidth',1,'MarkerSize',10);
hold on;
plot(X(n+1:2*n,1),X(n+1:2*n,2),'b*','LineWidth',1,'MarkerSize',10);
hold on;
plot( x1,y1,'k','LineWidth',1,'MarkerSize',10);
hold on;
plot( x1,y2,'k-.','LineWidth',1,'MarkerSize',10);
hold on;
plot( x1,y3,'k-.','LineWidth',1,'MarkerSize',10);
hold on;
plot(X(alpha>0,1),X(alpha>0,2),'rs','LineWidth',1,'MarkerSize',10); % 支持向量
hold on;
plot(X(alpha<C&alpha>0,1),X(alpha<C&alpha>0,2),'rs','MarkerFaceColor','r','LineWidth',1,'MarkerSize',10); % 间隔边界上的支持向量
hold on;
xlabel('x axis');
ylabel('y axis');
set(gca,'FontSize',10)
legend('class 1','class 2','classification surface','boundary','boundary','support vectors','support vectors on boundary');

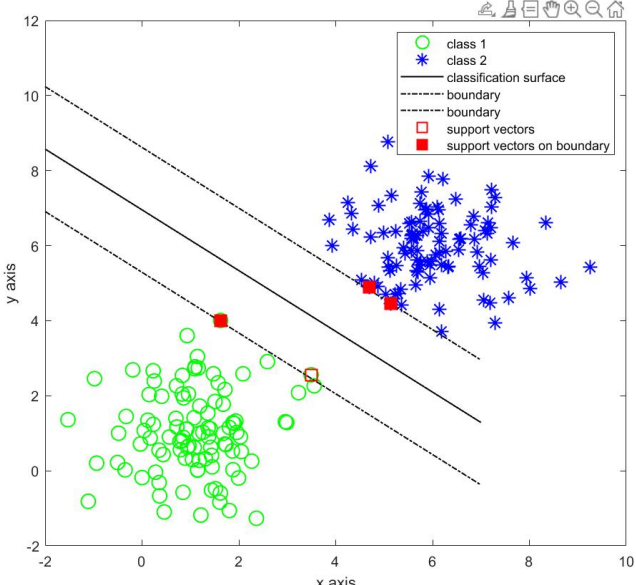
```

## 六、展示对比

以下通过修改不同参数，调试模型。改变的参数分别为样本量  $n$ 、惩罚参数  $\text{beta}$  ( $\beta$ )、惩罚参数  $C$ 、步长/学习率  $\text{eta}$  ( $\eta$ )、迭代次数  $m$ 。经过调试，源代码中的参数是合理的。另外，中心点的设置将影响数据点是否线性可分。 $\alpha$  和  $\lambda$  作为迭代的参数，其初值只要设置合理即可，并无影响)

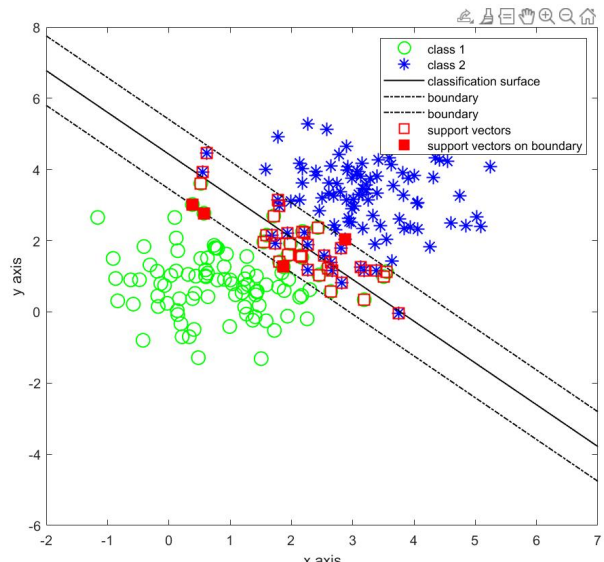
1、将中心点 2 设为 (6, 6)，数据集基本线性可分

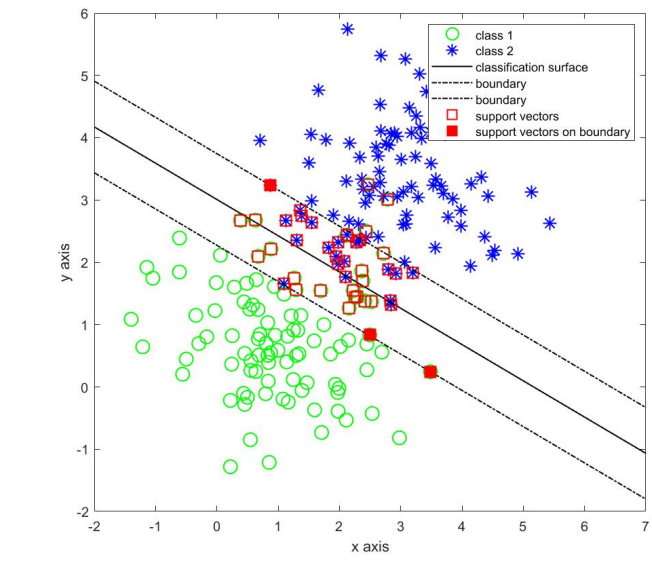
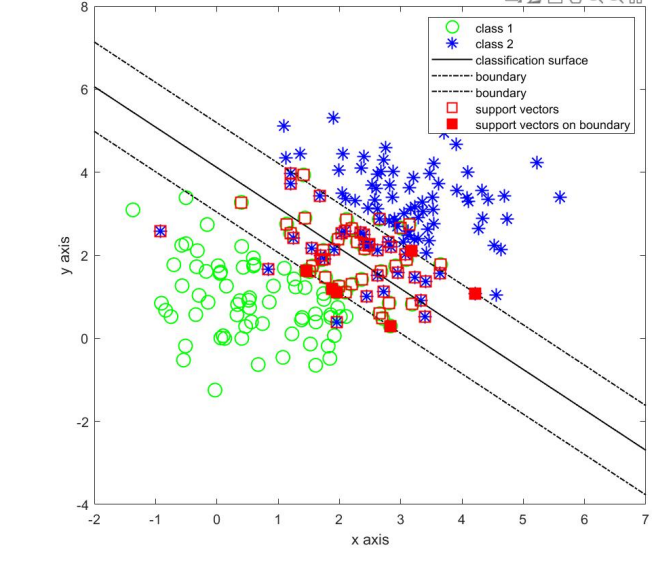
图三（测试）	线性增 广拉格 朗日函 数	合 页 损 失 函数	耗 时 (s)
--------	------------------------	------------------	------------

	0. 3131 054952 66735	1. 071 43227 66946 52	3. 57 8271
---	----------------------------	--------------------------------	---------------

线性可分支持向量机对参数的要求较低，不做过多展示，以下着重展现线性不可分支持向量机参数的调试过程。

2、将中心点 2 设为 (3, 3)，数据集变得线性不可分，连续重复 3 次

次数	图三（测试）	线性增 广拉格 朗日函 数	合页 损失 函数	耗时 (s)
1		-10. 219 1	34. 0 718	3. 3 116 74

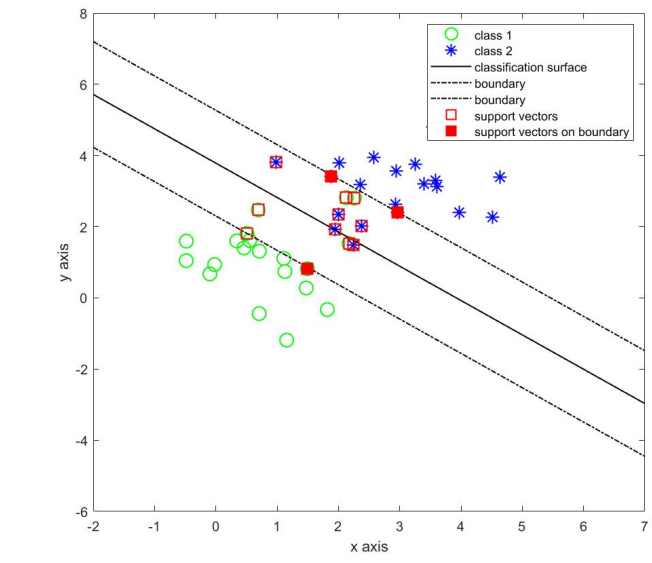
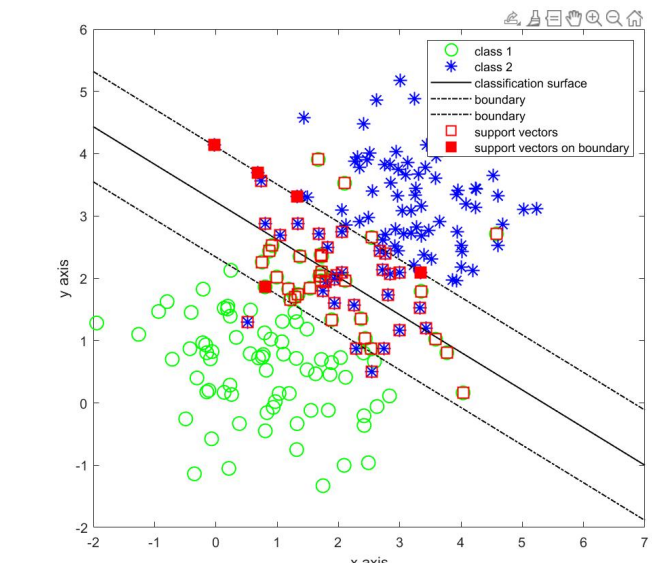
2		-11.374 6	37.9 191	3.5 532 34
3		-18.442 8	61.4 939	3.8 334 96

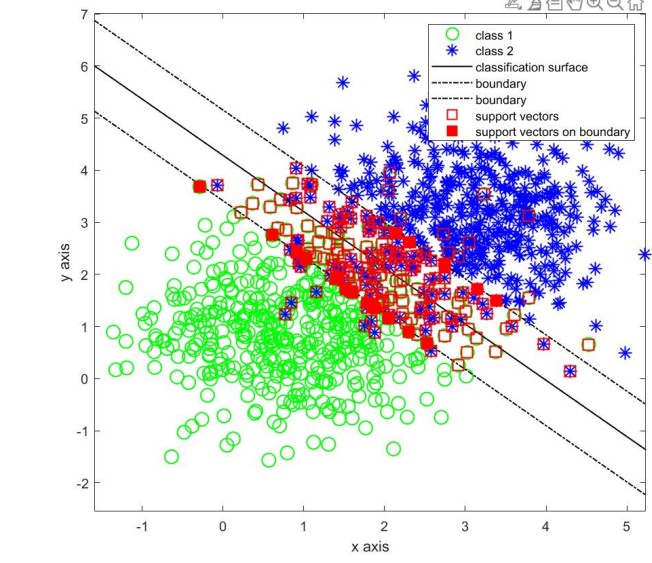
通过观察图像可以发现，SVM 模型稳定地较好地完成了分类任务，并完美地将支持向量尤其是间隔边界上的支持向量绘制了出来。

然而，通过计算发现，在一定范围内调节参数，并无法使每个支持向量计算出的  $b$  唯一，其总是在一段小的区间内，这说明在保守的参数设置（主要顾及运行时间）下，算法并没有完全收敛。

3、 $\beta=0.1$ ,  $C=0.3$ ,  $\eta=0.00005$ ,  $m=100000$ , 改动  $n$

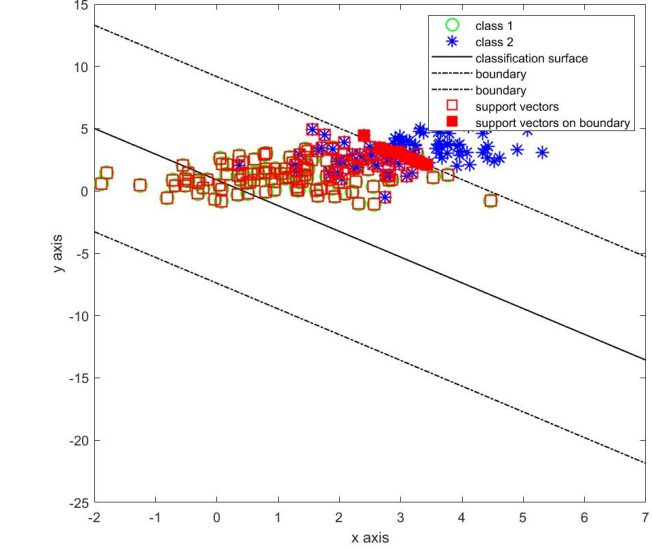
n	图三（测试）	线性增 广拉格 朗日函 数	合页 损失 函数	耗 时 (s)
---	--------	------------------------	----------------	---------------

20	<div><div>文件(F) 编辑(E) 查看(V) 插入(I) 工具(T) 桌面(D) 窗口(W) 帮助(H)</div><div></div></div>	-3.0597	10.272	0.252857
100	<div><div>文件(F) 编辑(E) 查看(V) 插入(I) 工具(T) 桌面(D) 窗口(W) 帮助(H)</div><div></div></div>	-16.4603	54.8746	4.114969

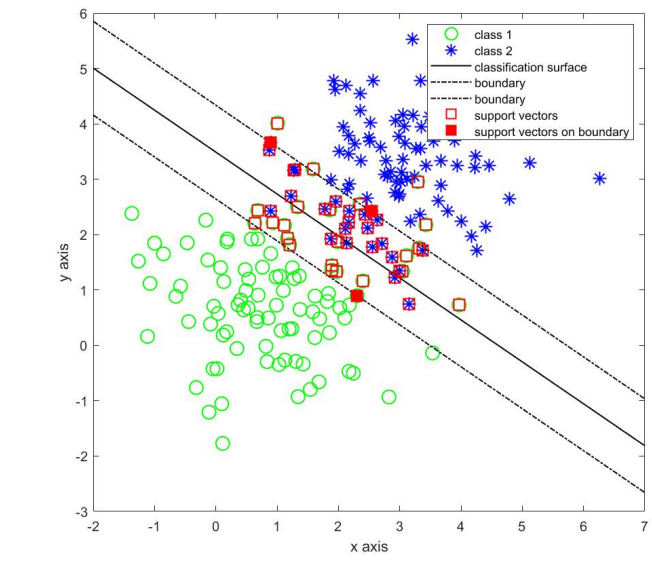
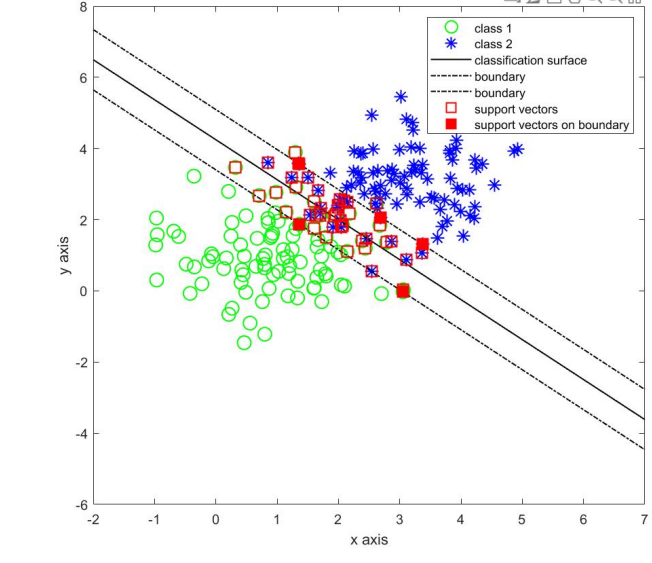
500		-60.2266	200.9428	190.624911
-----	---	----------	----------	------------

通过增加数据样本量可以发现，两个函数的结果绝对值与之正相关，时间上更是几何关系。虽然保持了良好的分类效果，并完美标注了支持向量，但是时间上却和前几个算法不在同一个量级上。

4、 $n=100$ ,  $C=0.3$ ,  $\eta=0.00005$ ,  $m=100000$ , 改动  $\beta$

b e t a	图三（测试）	线性增 广拉格 朗日函 数	合页 损失 函数	耗 时 (s)
0		-41.8952	139.2785	3.585339



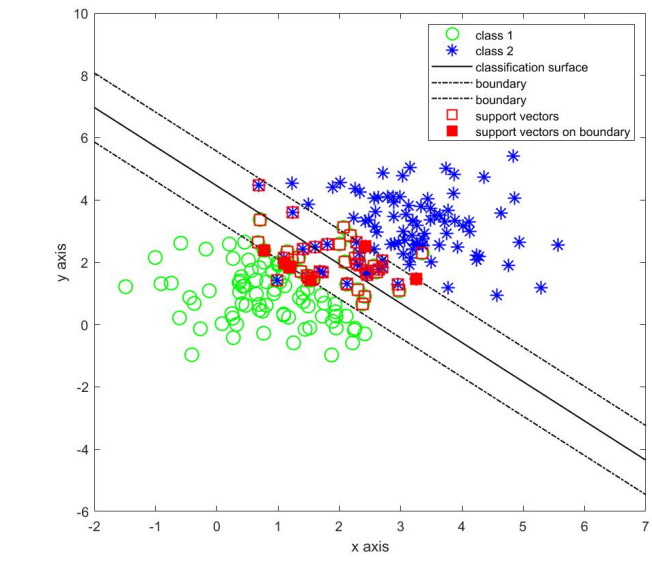
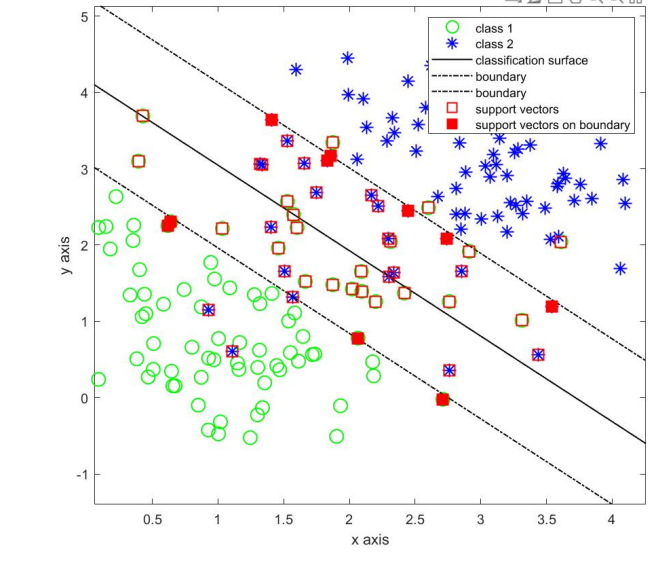
0 . 0 1	<div><div>文件(F) 编辑(E) 查看(V) 插入(I) 工具(T) 桌面(D) 窗口(W) 帮助(H)</div><div></div></div>	-12.462 1	41.5 426	3.5 394 52
0 . 1	<div><div>文件(F) 编辑(E) 查看(V) 插入(I) 工具(T) 桌面(D) 窗口(W) 帮助(H)</div><div></div></div>	-12.030 2	40.1 209	3.3 794 29

1		-12.424 5	41.4 220	3.1 874 16
---	--	--------------	-------------	------------------

在惩罚参数  $\beta$  等于 0 时，模型完全无法正常运行，这是由于在迭代中，以其为系数的项并未起到作用。而通过对比可以发现，在惩罚参数  $\beta$  增大的过程中，两个函数值基本不发生变化，这说明在其他参数合适而该参数合理的情况下，其对结果影响不大，而运行时间与其反相关。

5、 $n=100$ ,  $\beta=0.1$ ,  $\eta=0.00005$ ,  $m=100000$ , 改动 C

C	图三（测试）	线性增 广拉格 朗日函 数	合页 损失 函数	耗 时 (s)
0		-0.7957	79.5 680	3.3 473 45

0 . 3		-12.902 1	43.0 161	3.3 857 67
1		-42.773 7	42.8 846	3.6 598 81

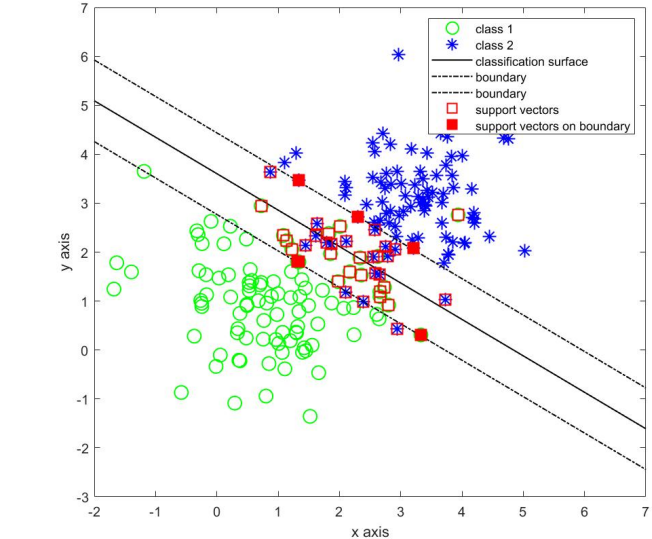
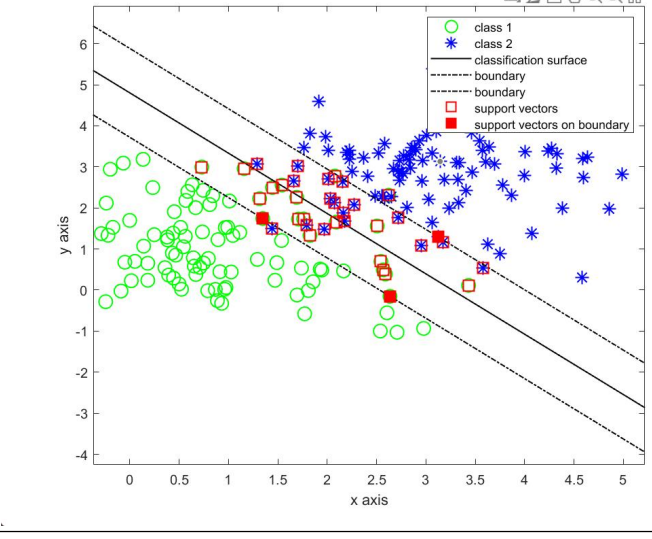
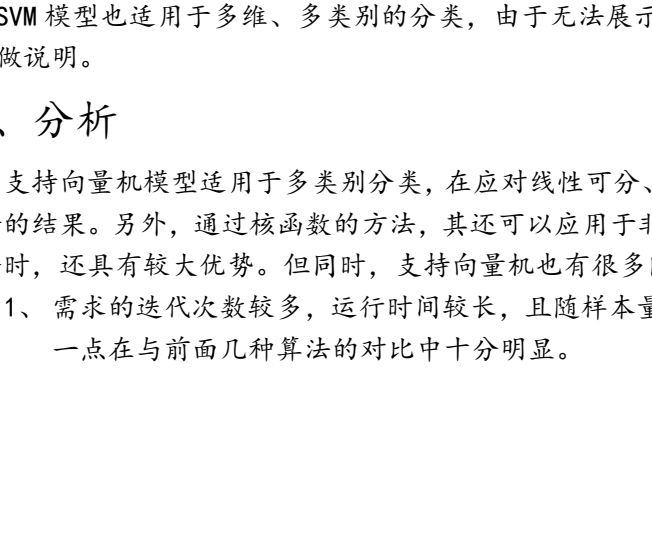
通过对比可以发现,在惩罚参数  $C=0$  时,没有支持向量,代码无法运行;在其过小 ( $C=0.01$ ) 时,间隔边界上的支持向量没有全部标注出来;而在其过大 ( $C=1$ ) 时,在间隔边界上的支持向量并不都恰好在间隔边界线上。这里特意将图像放大以便识别,通过两个函数的结果也可得出相应结论。

6、 $n=100$ ,  $\beta=0.1$ ,  $C=0.3$ ,  $m=100000$ , 改动  $\eta$

e t a	图三 (测试)	线性增 广拉格 朗日函 数	合页 损失 函数	耗 时 (s)
-------------	---------	------------------------	----------------	---------------

0 . 0 5	<div>文件(F) 编辑(E) 查看(V) 插入(I) 工具(T) 桌面(D) 窗口(W) 帮助(H)</div> <div><p>A scatter plot showing two classes of data points: class 1 (green circles) and class 2 (blue asterisks). A solid black line represents the classification surface, separating the two classes. Dashed lines represent the boundaries. Red squares indicate support vectors, and red squares on the dashed lines indicate support vectors on the boundary. The x-axis ranges from -2 to 7, and the y-axis ranges from -6 to 6.</p></div>	919. 178 5	2. 15 41e+ 04	3. 3 316 30
0 . 0 0 0 0 5	<div>文件(F) 编辑(E) 查看(V) 插入(I) 工具(T) 桌面(D) 窗口(W) 帮助(H)</div> <div><p>A scatter plot showing two classes of data points: class 1 (green circles) and class 2 (blue asterisks). Multiple solid black lines represent classification surfaces, separating the two classes. Dashed lines represent the boundaries. Red squares indicate support vectors, and red squares on the dashed lines indicate support vectors on the boundary. The x-axis ranges from -3 to 7, and the y-axis ranges from -6 to 8.</p></div>	-12. 862 3	42. 9 158	3. 6 231 75



10000		-10.652	35.5	3.3
20000		2	399	82214
30000		-9.2968	30.9	44.
40000			892	876
50000				205

在迭代次数不断增长的过程中，可以发现两个函数的绝对值在缩小，这表明结果在逐渐变好。而在迭代次数不够时，模型不能很好的呈现分类结果。相应的，运行时间也与迭代次数正相关。

8、SVM 模型也适用于多维、多类别的分类，由于无法展示图像或需改动代码过多，这里不做说明。

## 七、分析

支持向量机模型适用于多类别分类，在应对线性可分、线性不可分的情况下都可以取得较好的结果。另外，通过核函数的方法，其还可以应用于非线性可分的情况。在处理高维的数据时，还具有较大优势。但同时，支持向量机也有很多问题，比如

- 1、需求的迭代次数较多，运行时间较长，且随样本量的增加呈现几何倍数的增加。这一点在与前面几种算法的对比中十分明显。

## 八、附加题

1、见三、。

2、见六、4、6、。

笔记如下（截取了中国大百科全书第三版的相关内容，并加入了自己的理解）：

对等式约束非线性规划问题

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = 1, 2, \dots, p \end{aligned}$$

其增广拉格朗日函数(Augmented Lagrange function)定义为

$$L_\beta(x, \lambda) = f(x) + \sum_{j=1}^p (\lambda_j h_j(x) + \frac{\beta}{2} (h_j(x))^2)$$

式中  $\lambda \in R^p$  为拉格朗日乘子， $\beta > 0$  为罚参数。而迭代方法

$$\begin{cases} x^{k+1} \in \operatorname{argmin}_x L_\beta(x, \lambda^k) \\ \lambda^{k+1} = \lambda^k + \beta h(x^{k+1}) \end{cases}$$

称为增广拉格朗日乘子方法。这一方法由M.R.赫斯泰尼斯(Magnus Rodolph Hestenes)和M.J.鲍威尔(Michael James David Powell)于1969年独立提出，它克服了罚函数方法罚参数需要趋向于无穷大而引起的数值困难，是著名优化软件LANCELOT的基础。R.T.洛克菲勒(Ralph Tyrrell Rockafellar)给出了不等式约束及一般约束情形下的增广拉格朗日乘子法，使该方法成为约束优化问题的一类基本方法。

理解：增广拉格朗日函数法是处理等式约束的非线性规划问题的方法。在运算时，拉格朗日函数由三部分组成，一部分是原函数  $f(x)$ ，一部分是约束条件  $h_i$  与对应朗格朗日乘子  $\lambda_i$  的积的和，最后一部分是约束条件  $h_i$  的平方与惩罚参数  $\beta$  的积。在这个式子中，体现了欲求解的函数和提供的约束条件，并引入了非无穷大的惩罚参数。

3、见六、5、。